

INTRODUÇÃO

Uso de IA na saúde

A inteligência artificial tem transformado a saúde ao permitir diagnósticos mais rápidos, tratamentos personalizados e otimização de recursos clínicos. Modelos de aprendizado de máquina já são usados para detectar câncer em imagens radiológicas com precisão comparável à de especialistas, como no Google Health e no DeepMind (Reino Unido), que reduziram falsos positivos em mamografias em mais de 10%. No Hospital Albert Einstein (Brasil), algoritmos de IA auxiliam na predição de sepse, antecipando em até 6 horas o diagnóstico e reduzindo mortalidade em UTIs. Ferramentas como o ChatGPT e copilotos clínicos têm sido aplicadas em triagem de sintomas, apoio à decisão médica e elaboração de relatórios, economizando tempo administrativo. A IA também impulsiona a descoberta de fármacos (exemplo: AlphaFold da DeepMind, que prevê estruturas proteicas) e a análise de dados populacionais para vigilância epidemiológica. Esses usos demonstram benefícios mensuráveis como: menor tempo de resposta, redução de custos hospitalares e melhoria nos desfechos clínicos. O Sinasc e OpenDataSUS

OpenDataSUS - SINASC

O SINASC (Sistema de Informações sobre Nascidos Vivos) é uma base pública do OpenDataSUS, mantida pelo Ministério da Saúde do Brasil, que reúne registros de todos os nascimentos ocorridos no país. Ele contém dados da Declaração de Nascido Vivo (DNV), incluindo informações sobre a mãe (idade, escolaridade, tipo de parto), o recém-nascido (peso, idade gestacional, índices de Apgar) e o local do parto. O sistema é amplamente utilizado para pesquisa em saúde pública, monitoramento da mortalidade infantil e planejamento de políticas de atenção materno-infantil, sendo uma das principais fontes nacionais de dados demográficos e epidemiológicos.

O Índice APGAR

O Apgar é um índice clínico criado pela anestesiolegista Virginia Apgar em 1952 para avaliar rapidamente as condições do recém-nascido logo após o parto. Ele mede cinco parâmetros — frequência cardíaca, esforço respiratório, tônus muscular, irritabilidade reflexa e cor da pele — cada um pontuado de 0 a 2, totalizando um escore de 0 a 10. A avaliação é feita normalmente no 1º e 5º minutos de vida, podendo ser repetida posteriormente se necessário. Escores entre 7 e 10 indicam boa vitalidade, enquanto valores iguais ou inferiores a 7 sugerem necessidade de intervenção imediata para evitar complicações.

ENTENDIMENTO CLÍNICO

A escala de tempo para detectar e intervir em problemas neonatais é extremamente curta, muitas vezes limitada a minutos ou segundos após o nascimento. Nessa janela crítica, as práticas médicas e de enfermagem adotadas podem fazer a diferença entre salvar vidas e prevenir sequelas neurológicas graves. Diversos estudos e protocolos clínicos recomendam a avaliação imediata do recém-nascido e o início rápido de intervenções, como manobras de reanimação, para garantir o melhor prognóstico possível.

O Manual MSD (2024) destaca que "imediatamente após o parto, devem-se avaliar, no neonato, esforço respiratório, batimentos cardíacos, cor, tônus e irritabilidade dos reflexos, todos componentes-chave para índice de Apgar no 1º e no 5º minuto após o nascimento. Índices de Apgar entre 7 e 10 indicam transição suave para a vida extrauterina; escores ≤ 7 aos 5 minutos estão vinculados a taxas elevadas de morbidade e mortalidade neonatais. Essa avaliação nos primeiros minutos é decisiva para a rápida identificação de necessidades de intervenção" ([msdmanuals.com](https://www.msdmanuals.com)).

No Hospital e Maternidade José Martiniano de Alencar (2023), reforça-se que "a primeira média é dada no primeiro minuto, depois no quinto e no décimo minutos. Crianças com pontuações inferiores a 7 recebem assistência imediata visando ao aumento da classificação. A falta de oxigenação pode ocorrer rapidamente, por isso a importância da presença do neonatologista para assistência no parto" (saude.ce.gov.br).

A Unimed BH (2025) explica que "nos primeiros minutos após o nascimento, a equipe realiza avaliação clínica e verificação dos sinais vitais do recém-nascido, incluindo o Índice de Apgar no 1º e 5º minutos, podendo ser reavaliado no 10º, 15º e 20º minutos conforme necessidade. Essa avaliação contínua garante detecção precoce de problemas que podem evoluir rapidamente" (viverbem.unimedbh.com.br).

Por fim, o Guia de Atenção à Saúde da Criança, Paraná (2022), destaca que "se o recém-nascido não estiver respirando ou apresentar hipotonia, recomenda-se início de manobras iniciais em no máximo 30 segundos, com ventilação positiva nos primeiros 60 segundos, considerado o 'minuto de ouro' para reanimação e melhores prognósticos" (saude.pr.gov.br).

Para que essas intervenções sejam eficazes, é fundamental prever rapidamente o estado do bebê. A utilização de modelos de machine learning capazes de prever o escore APGAR5 poucos minutos antes da avaliação real torna-se indispensável. Ao antecipar a necessidade de suporte técnico, esses modelos permitem que equipes médicas estejam preparadas para agir de forma imediata e eficiente, reduzindo o tempo até o atendimento e aumentando as chances de sucesso nas intervenções.

Além disso, a rapidez de acesso a essa predição é essencial. A disponibilização do modelo preditivo por meio de um webapp torna possível a consulta móvel, facilitando o uso em diferentes ambientes hospitalares e permitindo decisões instantâneas na sala de parto ou UTI neonatal. Dessa forma, a combinação de uma predição rápida com acesso móvel ao modelo configura uma ferramenta estratégica para otimizar práticas clínicas, garantindo agilidade, precisão e melhor qualidade no cuidado ao recém-nascido.

Em suma, dada a curta escala de tempo para intervenção pós-nascimento e os benefícios comprovados da detecção precoce, o uso de um webapp que ofereça predição rápida e móvel do APGAR5 justifica-se plenamente como uma inovação com alto impacto positivo na saúde neonatal.

Tabela de Benefícios da Previsão Antecipada do Índice Apgar5

Problema Clínico	Benefício da Previsão Antecipada do Apgar5
Baixo escore de Apgar (≤ 7) aos 5 minutos	Permite alocar equipe e iniciar reanimação imediatamente, reduzindo o tempo de resposta.
Hipóxia aguda / falta de oxigenação	Antecipação do risco possibilita ventilação precoce e reduz lesão hipóxica.
Necessidade imediata de manobras de reanimação	Garante que equipe e equipamentos estejam prontos para agir no “minuto de ouro”.
Taquicardia/bradicardia e insuficiência circulatória	Alerta precoce acelera suporte hemodinâmico e monitorização intensiva.
Depressão do tônus e hipotonia	Facilita intervenções rápidas para restaurar tônus e respiração.
Comprometimento respiratório / apneia	Permite ventilação imediata e reduz risco de dano cerebral.
Irritabilidade/alteração dos reflexos	Antecipação favorece exame neurológico precoce e medidas protetoras.
Aumento da morbidade neonatal	Reduz a incidência e severidade de complicações imediatas.
Aumento da mortalidade neonatal	Diminui mortes associadas à asfixia e complicações intraparto.
Risco de paralisia cerebral e sequelas neurológicas	Intervenção mais rápida reduz dano neurológico permanente.
Evolução rápida de complicações intraparto	Antecipação evita progressão para estado crítico.
Falha/atraso na detecção clínica	Modelo atua como segundo verificador, reduzindo erro humano.
Necessidade de presença do neonatologista	Permite acionar equipe especializada antes do evento crítico.
Planejamento hospitalar inadequado	Melhora alocação de leitos, recursos e fluxo na UTI neonatal.
Impacto em saúde pública	Reduz taxas de mortalidade e morbidade, diminuindo custo sistêmico.
Demora na triagem contínua	Otimiza reavaliações e prioriza casos de maior risco.

Intervalo crítico entre avaliação e intervenção	Encurta o tempo até intervenção, melhorando desfechos clínicos.
---	---

Dependência de exames tardios (teste do pezinho/coraçãozinho)	Complementa diagnóstico precoce e reforça resposta clínica imediata.
---	--

ENTENDIMENTO E PREPARAÇÃO DOS DADOS

Os dados utilizados são provenientes da plataforma OpenDatasus, onde foram baixados os arquivos CSV do Sistema de Informações sobre Nascidos Vivos (SINASC) para os anos de 2015 a 2024. Cada ano de SINASC estava armazenado em arquivos separados, com tamanhos aproximados entre 800 MB e 1 GB, totalizando um conjunto de dados muito grande.

O dataset original contém cerca de 69 variáveis, incluindo características demográficas, clínicas e relacionadas ao parto. Foi observada uma inconsistência no formato de algumas variáveis, como features em letras minúsculas no ano de 2016, o que exigiu padronização para garantir uniformidade. Para assegurar a qualidade do dataset, foram removidas todas as linhas com dados ausentes nas variáveis selecionadas para modelagem, resultando em mais de 10 milhões de registros válidos.

O processamento desses arquivos enfrentou desafios por causa do tamanho dos CSVs. Para isso, utilizou-se técnicas de leitura em chunks (partições do arquivo para não sobrecarregar a memória), sampling para amostragem representativa e manipulação automática de escrita de arquivos CSV em partes, evitando problemas de overflow de memória.

O processamento levou em consideração a estrutura formal descrita nos documentos oficiais do SINASC, garantindo o alinhamento com os dados originais e facilitando a interpretação e replicação.

Esta abordagem permitiu construir um dataset robusto e confiável para alimentar os modelos de machine learning empregados na predição do APGAR5, destacando a escolha do LightGBM devido à sua rápida capacidade de treinamento em grandes datasets, essencial para o trabalho com dados tão volumosos.

MODELAGEM

LightGBM

LightGBM (Light Gradient Boosting Machine) é uma biblioteca desenvolvida pela Microsoft baseada em *gradient boosting*, otimizada para alto desempenho em grandes volumes de dados. Utiliza estruturas como árvores baseadas em histogramas e o método Leaf-wise (crescimento por folhas), que acelera o treinamento e melhora a precisão em relação a abordagens tradicionais como XGBoost.

Foi escolhido neste projeto por ser extremamente rápido, escalável e preciso em tarefas de regressão com bases extensas e complexas, como a do SINASC. Além disso, lida bem com valores ausentes, features categóricas e permite ajuste fino de hiperparâmetros, tornando-o ideal para prever o índice Apgar5 com eficiência e baixo custo computacional.

O LightGBM funciona criando várias árvores de decisão pequenas, uma após a outra. Cada nova árvore tenta corrigir os erros que as anteriores cometeram.

Ele aprende gradualmente, ajustando os pesos das observações mal previstas para melhorar a precisão a cada etapa — esse processo é chamado de gradient boosting.

Diferente de outros modelos, o LightGBM constrói as árvores de forma Leaf-wise (crescendo pelos ramos mais promissores), o que o torna mais rápido e eficiente, especialmente em bases grandes. Assim, ele consegue prever valores contínuos (como o Apgar5) com boa precisão e em menos tempo de processamento.

Optuna

O Optuna é uma biblioteca de otimização automática de hiperparâmetros baseada em *machine learning*, usada para encontrar a melhor combinação de parâmetros de um modelo de forma eficiente e sem necessidade de testes manuais. Ele utiliza técnicas de amostragem inteligente (como *Tree-structured Parzen Estimator* – TPE) para explorar o espaço de parâmetros e concentrar as tentativas nas combinações mais promissoras.

No projeto, o Optuna foi aplicado para otimizar os hiperparâmetros do modelo LightGBM, ajustando automaticamente variáveis como *learning_rate*, *num_leaves*, *subsample* e *regularização* (*lambda_l1* e *lambda_l2*). O objetivo definido foi minimizar o erro médio absoluto (MAE) na predição do Apgar5, garantindo melhor equilíbrio entre precisão e generalização.

Após 100 tentativas, o Optuna identificou o conjunto de parâmetros que produziu o menor MAE, além de permitir visualizar a convergência da métrica ao longo dos *trials*, mostrando graficamente como o modelo evoluiu até atingir o melhor desempenho.

A modelagem do projeto foi conduzida seguindo o processo CRISP-DM, o que garantiu uma estrutura organizada e rigorosa nas etapas de preparação, análise e validação dos modelos. A seleção de variáveis foi realizada com base na importância preditiva calculada por técnicas explicativas como SHAP (SHapley Additive exPlanations), permitindo identificar as variáveis mais relevantes para prever o Apgar5.

Modelos iniciais baseados em LightGBM Classifier não apresentaram desempenho satisfatório, mesmo após otimização de hiperparâmetros com o Optuna. A melhor performance foi alcançada com a abordagem regressiva utilizando LightGBM Regressor, combinada à otimização automática via Optuna e validação cruzada K-Fold.

Esse resultado representa boa precisão, considerando que o Apgar é medido em uma escala de 0 a 10, e demonstra o potencial do modelo para prever o escore Apgar5 em tempo real a partir de dados clínicos iniciais, permitindo ações antecipadas na assistência neonatal e contribuindo para melhor resposta em situações críticas.

Avaliação de Resultados

Métrica

O MAE (Mean Absolute Error) foi usado para avaliar o modelo de predição do Apgar5 porque é uma métrica simples, direta e fácil de interpretar. Ele mostra o erro médio entre o valor previsto e o real, usando a mesma escala do Apgar (0 a 10), o que facilita entender quanto o modelo erra em termos práticos.

Diferente de métricas como o RMSE, que dá mais peso a erros grandes, o MAE trata todos os erros da mesma forma, sendo mais equilibrado e menos sensível a valores extremos. Isso é importante porque o Apgar é uma pontuação discreta e com pouca variação.

Além disso, o MAE é mais estável para ajustar modelos de regressão e é bastante usado em estudos clínicos e previsões médicas, o que o torna adequado para este tipo de análise.

Resultados

Durante a otimização com o Optuna, cada tentativa (trial) testou uma combinação diferente de hiperparâmetros do modelo LightGBM, como taxa de aprendizado, número de folhas e fração de amostragem. Em cada teste, o modelo foi treinado e avaliado usando o erro médio absoluto (MAE) como métrica principal. O processo identificou automaticamente quais configurações geravam o menor erro. Ao final, o melhor conjunto de parâmetros foi obtido no trial 24, com MAE de aproximadamente 0,6367, representando o desempenho mais preciso entre todas as execuções.

DEPLOY

Streamlit e GitHub para Gerenciamento e Versionamento de Aplicações e Modelos de Machine Learning

O Streamlit foi utilizado como framework principal para o desenvolvimento da aplicação preditiva do Apgar5, permitindo transformar o modelo de regressão treinado em uma interface web interativa e responsiva. A aplicação possibilita a inserção de variáveis clínicas e demográficas em tempo real, exibindo imediatamente a previsão do escore Apgar5 e as métricas de desempenho associadas. Essa abordagem facilitou a validação prática do modelo e a visualização dos resultados de forma acessível a profissionais de saúde e analistas.

Em paralelo, o GitHub foi empregado para versionar todo o pipeline do projeto — incluindo scripts de pré-processamento, treinamento e otimização de hiperparâmetros, além do código do aplicativo Streamlit. O uso de repositórios permitiu o controle de versões dos modelos, facilitando a rastreabilidade das alterações, a integração contínua de novos dados e a manutenção colaborativa.

Essa estrutura combinada garante a reprodutibilidade dos experimentos, o gerenciamento eficiente das versões dos modelos e a evolução contínua da aplicação à medida que novos dados do SINASC são incorporados, mantendo o ciclo de aprendizado e melhoria do sistema de predição do Apgar5.

Referências

1. <https://www.tuasaude.com/escala-de-apgar/>
2. <https://unidombosco.edu.br/blog/escala-de-apgar-entenda/>
3. <https://www.msmanuals.com/pt/profissional/pediatria/problemas-perinatais/reanima%C3%A7%C3%A3o-neonatal>
4. <http://www.scielo.org.co/pdf/aven/v36n2/0121-4500-aven-36-02-197.pdf>
5. [http://www.cbra.org.br/pages/publicacoes/rbra/v38n1/pag54-59%20\(RB490%20Vassalo\).pdf](http://www.cbra.org.br/pages/publicacoes/rbra/v38n1/pag54-59%20(RB490%20Vassalo).pdf)
6. <https://sanarmed.com/escore-de-apgar/>
7. <https://www.medicina.ufmg.br/observaped/escala-de-apgar/>
8. https://www.saude.sp.gov.br/resources/ses/perfil/gestor/homepage/programa-de-fortalecimento-da-gestao-da-saude-no-estado-de-sao-paulo/consultas-publicas/manual_de_neonatologia.pdf
9. https://www.saude.pr.gov.br/sites/default/arquivos_restritos/files/documento/2020-07/pdf1.pdf
10. <https://editoraintegrar.com.br/publish/index.php/rem/article/download/3873/763/4628>